DATA MINING · FINAL PROJECT

用三个真实数据集
完成一次属于自己的数据挖掘研究

- 支付欺诈检测
- 酒店推荐预测
- 客户交易预测

分类 · 聚类 · 频繁模式挖掘 · 离群点检测

数据挖掘技术 助教组 · 2026 春季学期

OVERVIEW

三个数据集 · 三种现实场景

以下三个 Kaggle 公开数据集任选其一作为研究对象 — 不再要求向 Kaggle 提交结果，重点在课内方法的应用与分析。

PROJECT 01

信用卡支付欺诈检测

IEEE-CIS Fraud Detection

数据规模

≈ 59 万笔训练交易 / 393 维特征

任务性质

二分类 · 极端不平衡

适用方法

分类 + 离群检测

PROJECT 02

酒店预订聚类推荐

Expedia Hotel Recommendations

数据规模

≈ 3700 万次会话 / 100 个酒店簇

任务性质

多分类 · 推荐 / 聚类

适用方法

聚类 + 分类 + 关联

PROJECT 03

客户交易倾向预测

Santander Customer Transaction

数据规模

20 万样本 / 200 维匿名数值特征

任务性质

二分类 · 弱信号 / 同分布

适用方法

分类 + 特征/分布分析

IEEE-CIS Fraud Detection

在 96.5% 的正常交易里，找出那剩下 3.5% 的支付欺诈 — 一道经典的强不平衡二分类。

任务类型

二分类 / 异常检测

评估视角

ROC-AUC + PR / KS

数据规模

≈ 59 万笔 • 393 维

数据画像 • 关键挑战

DATA & CHALLENGES

- 极端类别不平衡 — 正负比约 3.5 : 96.5，朴素模型会把所有样本判为正常。
- 高基数类别变量 — 设备指纹 / IP / 邮箱 / 商户 ID 唯一值数以万计，One-Hot 直接爆。
- 明显的时间漂移 — 训练 / 测试官方按时间切，欺诈模式随月份演化。随机 KFold 即泄露。
- 字段含义匿名化 — C1–C14 / D1–D15 等只有编号，需要靠分布与相关性反推语义。

推荐方法栈

METHOD STACK

GBDT 系列分类
LightGBM / XGBoost + 类别权重 / 焦点损失

孤立森林 / LOF
把欺诈作为离群点处理

目标编码 + 平滑
高基数类别的关键技巧

时间感知验证
按 TransactionDT 前向滚动切分

阈值与代价分析
结合 PR 曲线与业务代价矩阵

Expedia Hotel Recommendations

依据用户搜索 / 点击 / 预订行为，把每次会话映射到 100 个酒店聚类之一 — 推荐 + 聚类的混合任务。

任务类型

多分类 / 推荐

评估视角

MAP@5 / Top-K 命中率

数据规模

≈ 3700 万 • 100 簇

数据画像 • 关键挑战

DATA & CHALLENGES

- 目标本身就是聚类 — 标签 hotel_cluster 是 Expedia 内部聚类结果，不是真酒店 ID。
- 搜索 vs. 预订双信号 — is_booking 标记区分浏览与下单，权重需要分别处理。
- 极度长尾 — 用户 / 目的地 / 设备分布严重幂律，少量热门簇支配评估。
- 时空 + 上下文特征 — 出行日期 / 入住时长 / 国家 / 渠道相互纠缠，需要交叉特征。

推荐方法栈

METHOD STACK

K-Means / 层次聚类
复刻 / 验证目标聚类结构

频繁模式挖掘
Apriori / FP-Growth 找共现目的地组合

协同过滤 + Embedding
user × destination × cluster 矩阵分解

梯度提升多分类
对热门簇做 Top-K 直推

MAP@5 阈值评估
对应多标签 / Top-K 评估

Santander Customer Transaction Prediction

200 维匿名数值特征，预测客户是否会发生某笔特定交易 — 弱信号 + 同分布带来的硬骨头。

任务类型

二分类 / 概率排序

评估视角

ROC-AUC

数据规模

20 万训练 + 20 万测试

数据画像 · 关键挑战

DATA & CHALLENGES

- 特征完全匿名 — var_0 ~ var_199 全为脱敏数值，没有任何业务语义可直接借用。
- 训练 / 测试同分布 — 测试集藏有合成样本，先甄别真伪再建模是高分团队的关键。
- 正例稀疏 (≈ 10%) — 正负失衡程度温和但仍偏斜，需对比代价敏感与重采样。
- 看似独立其实弱相关 — 字段对单变量近似独立，但联合分布里藏有信号。

推荐方法栈

METHOD STACK

单变量直方建模
对每个 var_i 计 KDE / WoE，迁回原书离散化

高斯朴素贝叶斯
做基线，验证 “特征独立性” 假设

LightGBM (按行训练)
经典 frequency encoding 技巧大有用武之地

聚类辅助分群
GMM / KMeans 把 20 万样本切成行为子群

ROC / PR 阈值搜索
对接概率排序与决策

METHOD MATRIX

把课上学过的四类方法 · 用进任意一个数据集

无论选哪个项目，下面四个角度至少各覆盖一种 。

01 分类 Classification

Decision Tree · GBDT · NB · SVM · NN

- 项目 1 / 3 - 直接用作主任务
- 项目 2 - 把酒店簇当多分类目标

02 聚类 Clustering

K-Means · DBSCAN · GMM · Hierarchical

- 项目 2 - 复刻 hotel_cluster 标签
- 项目 1 / 3 - 客户分群作辅助特征

03 频繁模式 Frequent Pattern

Apriori · FP-Growth · 序列模式

- 项目 2 - 共现目的地 / 渠道组合
- 项目 1 - 高频欺诈商户组合规则

04 离群检测 Outlier

iForest · LOF · 一类 SVM

- 项目 1 - 与监督方法对比
- 项目 3 - 测试集合成样本检测

提示：数据预处理（缺失 / 离散化 / 标准化）作为前置步骤，所有项目都默认要做。

GROUND RULES

做这件事的三个原则

01

方法对齐课程

报告必须明确写出用了哪些课上讲过的方法 — 分类 / 聚类 / 频繁模式 / 离群点检测，至少两类。

02

结论要有证据

图表 / 指标 / 消融实验是底线；任何 “某方法更好” 的判断都得给出对照实验或可视化证据。

03

工程严谨性

防止数据泄露、合理切分训练 / 验证、记录随机种子 — 工程坑会扣分，写得越透明越拿分。

DELIVERABLES

交付物 · 鼓励向 Kaggle 提交（非必需）

重点： 把这三个数据集当作研究对象，目标是 **一份完整的数据挖掘研究报告**，如有 Leaderboard 排名更好。

报 告 8 - 15 页

研究报告 (PDF)

- 数据画像 / 探索性分析 / 关键发现
- 方法选择动机 + 与课内方法的对应说明
- 至少两类课内方法的实验对比 (含图表)
- 失败案例 / 反思 / 局限性

代 码 Notebook 或 .py

可复现代码

- README 写明环境 / 数据下载 / 运行步骤
- 随机种子固定，一键可复现关键图表
- 数据预处理 / 训练 / 评估 三段清晰分层
- 无需 Kaggle 提交，本地评估即可，也鼓励进行提交

分 享 现场分享，加分

10 分钟分享 PPT

- 讲清楚为什么选这些方法
- 至少一张关键图能让人 5 秒读懂
- 回答 “最让你困惑的一点是什么”
- 如组队请说明分工

推荐参考的两本教材

不再绑定具体章节 — 哪一章对得上你做的内容，自己在报告里说清楚即可。

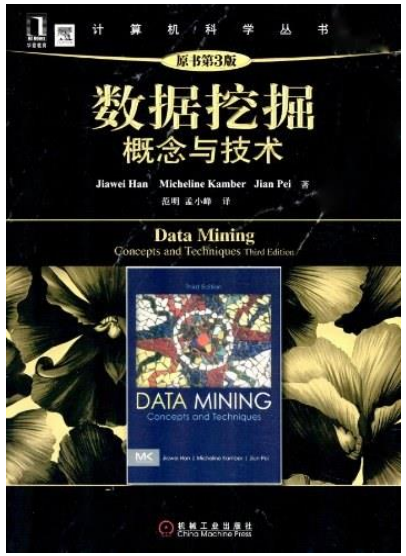

数据挖掘：概念与技术

Data Mining: Concepts and Techniques

Jiawei Han, Micheline Kamber, Jian Pei

机械工业出版社 · 原书第 3 版

体系完整 • 概念严谨

覆盖数据预处理、频繁模式、分类、聚类与离群挖掘，正好对应本作业的四个角度。

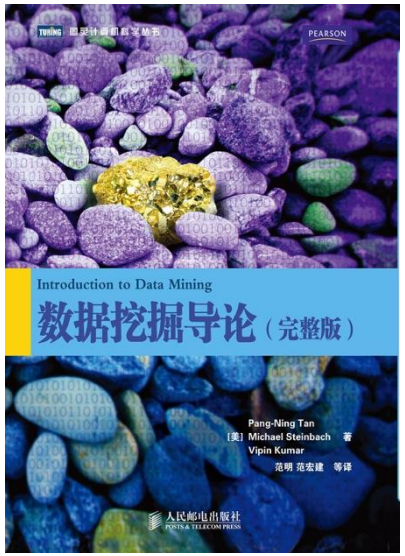

数据挖掘导论

Introduction to Data Mining

Pang-Ning Tan, Michael Steinbach, Vipin Kumar

人民邮电出版社 · 完整版

例题丰富 • 易上手

围绕数据 / 分类 / 关联分析 / 聚类 / 异常检测五大主题，配有大量例题与可读图示。

评分维度 & 关键时间节点

评分维度 • 共 100 分

GRADING RUBRIC

15	**数据探索 & 画像**	字段 / 分布 / 缺失 / 时间
25	**课内方法的应用**	至少覆盖两类: 分类·聚类·频繁·离群
20	**实验设计 & 验证**	切分合理 / 对照清晰 / 防泄露
20	**结果分析 & 图表**	每个结论都有图表或指标支撑
20	**报告写作 & 分享**	讲得清楚 + 说得上来

关键时间节点

MILESTONES

第 8 周
选题发布
助教组发题, 各组确认 (1 - 3 人)

第 12 周
提交截止
上交研究报告 + 可运行代码

第 13 - 14 周
现场分享
各组 15 min 讲解

Q & A

挑一个数据集，用课上学过的方法把它讲透。

分数来自方法的深度，不来自排行榜。

数据挖掘技术 · 助教组 · 随时来问